

Segmentación y Cuantificación Automática de los Ventrículos Laterales en Resonancia Magnética Fetal para el Apoyo Diagnóstico de la Ventriculomegalia

Ana Sofía López Romero (A01067828), Andrea Nathaly Ochoa Torres (A01645806),
Viviana Alejandre Paniagua (A01645185), Laisha Nicole Cortés Montes (A01253758)

*Procesamiento de Imágenes Médicas · Grupo 601
Tecnológico de Monterrey, Campus Guadalajara · Junio de 2026*

Resumen—La ventriculomegalia fetal es una de las anomalías del sistema nervioso central más frecuentemente detectadas en estudios prenatales y se define clínicamente cuando el diámetro atrial del ventrículo lateral alcanza o supera los 10 mm en el plano axial transventricular. Su medición manual presenta variabilidad inter-observador, lo que motiva el desarrollo de herramientas computacionales reproducibles. Este trabajo implementa y evalúa un *pipeline* semiautomatizado de procesamiento digital de imágenes de resonancia magnética (MRI) fetal ponderada en T2, organizado en cinco etapas (análisis digital, reducción de ruido, segmentación, cuantificación y clasificación) más una etapa de validación con aprendizaje profundo. El método combina normalización por percentiles, realce de contraste adaptativo (CLAHE), filtrado bilateral y una estrategia de segmentación por hemisferios basada en la región intracerebral interna, que resuelve la confusión habitual entre el líquido cefalorraquídeo (LCR) ventricular y el subaracnoideo. El diámetro atrial se estima mediante el rectángulo de área mínima y se clasifica según el criterio de Cardoza. Como segundo criterio se entrenó una Attention U-Net con codificador EfficientNet-B0 preentrenado mediante *transfer learning*. El sistema se evaluó sobre diez volúmenes (uno hospitalario de buena calidad, cuatro hospitalarios de reconstrucción deficiente y cinco axiales de alta calidad), obteniendo segmentaciones anatómicamente consistentes con un Dice promedio de 0.814 e IoU de 0.694. Los volúmenes axiales de alta calidad produjeron segmentaciones más confiables (CV < 0.21) que los hospitalarios de mala reconstrucción.

Index Terms—ventriculomegalia fetal, resonancia magnética, segmentación de imágenes, procesamiento digital de imágenes, U-Net, transfer learning, diámetro atrial, CLAHE, líquido cefalorraquídeo.

I. INTRODUCCIÓN

La ventriculomegalia fetal corresponde a la dilatación anormal de los ventrículos laterales del cerebro en desarrollo y es uno de los hallazgos neurológicos prenatales más comunes. El criterio clínico más ampliamente aceptado, establecido por Cardoza *et al.* [1], define el diagnóstico cuando el diámetro atrial del ventrículo lateral es mayor o igual a 10 mm, medido en el plano axial transventricular. A partir de este umbral se establece la clasificación clínica habitual [2]: normal (< 10 mm), leve (10–12 mm), moderada (12–15 mm) y severa (> 15 mm).

Los ventrículos laterales contienen LCR, un fluido transparente que actúa como amortiguador mecánico del sistema nervioso central, participa en el intercambio metabólico y contribuye a la regulación de la presión intracraneal. En las secuencias de MRI fetal ponderadas en T2, el LCR aparece hiperintenso debido a su alto contenido de agua y a sus tiempos de relajación prolongados, lo que facilita su identificación mediante técnicas de procesamiento digital basadas en intensidad. Aunque el ultrasonido es el método inicial de cribado, la MRI fetal se utiliza como modalidad complementaria para confirmar la ventriculomegalia, evaluar malformaciones asociadas y analizar la morfología cerebral con mayor detalle.

Dado que la medición del diámetro atrial suele realizarse de forma manual, con la consiguiente variabilidad inter-observador, el desarrollo de herramientas de segmentación y cuantificación automática puede mejorar la reproducibilidad diagnóstica.

La importancia clínica de una cuantificación reproducible radica en que el diámetro atrial es un predictor pronóstico: la ventriculomegalia leve aislada suele tener buen pronóstico, mientras que las formas moderada y severa se asocian con mayor riesgo de anomalías estructurales y del neurodesarrollo. Una diferencia de pocos milímetros puede modificar la categoría diagnóstica y, con ella, el seguimiento y consejo prenatal. Por ello, reducir la variabilidad inter-observador mediante herramientas automáticas tiene un impacto directo en la consistencia de la toma de decisiones.

Este trabajo aborda dicho problema mediante un *pipeline* estructurado en cinco etapas y una etapa adicional de validación con aprendizaje profundo. La contribución metodológica central es una estrategia de segmentación que evita la confusión entre el LCR ventricular y el subaracnoideo restringiendo la búsqueda a la región intracerebral interna, junto con un criterio automático de selección del corte transventricular basado en la presencia de dos componentes ventriculares simétricos.

II. ESTADO DEL ARTE

II-A. Métodos clásicos de segmentación

La umbralización de Otsu calcula el umbral óptimo maximizando la varianza entre clases; es robusta bajo intensidad uniforme pero sensible a gradientes de iluminación, frecuentes en MRI fetal por inhomogeneidad de campo. Las técnicas de umbralización adaptativa y de agrupamiento (k -means) permiten separar el LCR hiperintenso del tejido cerebral sin requerir entrenamiento. Su ventaja es la interpretabilidad total y la ejecución en CPU; su desventaja, el rendimiento limitado ante ruido y solapamiento de estructuras.

II-B. Corrección de inhomogeneidad y realce

La corrección de sesgo de campo (p. ej. N4ITK [10]) y el realce de contraste adaptativo con limitación de amplificación (CLAHE) son pasos estándar para homogeneizar el contraste local antes de la segmentación, especialmente en adquisiciones fetales donde el movimiento y la reconstrucción degradan la señal.

II-C. Segmentación con aprendizaje profundo

La arquitectura U-Net [3] combina contexto semántico y detalle espacial mediante conexiones de salto, y constituye el estándar en segmentación biomédica. Variantes como V-Net [7], Attention U-Net [4] y nnU-Net [8] han mejorado progresivamente el desempeño. En el dominio fetal, el *benchmark* FeTA [9] proporcionó anotaciones multi-tejido. La principal limitación de estos métodos es la necesidad de GPU y de grandes volúmenes de datos anotados a nivel de píxel, escasos en el contexto fetal.

II-D. Área de oportunidad

Dos brechas motivan este trabajo: la necesidad de una línea base clásica interpretable y reproducible para la cuantificación del diámetro atrial, y la ausencia de una estrategia robusta que distinga el LCR ventricular del subaracnoideo en adquisiciones de calidad heterogénea.

III. CONJUNTO DE DATOS

Se emplearon diez volúmenes de MRI fetal ponderada en T2 organizados en tres grupos: un volumen hospitalario de buena calidad (56-good), cuatro hospitalarios de reconstrucción deficiente (49, 66, 05 y 96-badrecon) y cinco volúmenes axiales de alta calidad (t2-t21 a t2-t25). La Tabla I resume sus características digitales. Los volúmenes hospitalarios se adquirieron en plano sagital con resolución isotrópica de 0.75 mm; los volúmenes axiales presentan resolución de 0.50 mm. A los volúmenes de reconstrucción deficiente se les aplicó un filtrado adicional *Non-Local Means* (NLM) previo a la segmentación, dada su menor relación señal/ruido.

Cuadro I
CARACTERIZACIÓN DIGITAL DE LA BASE DE DATOS (ETAPA I)

Volumen	Tipo	Plano	Forma (X,Y,Z)	Vóx.	z	SNR
56-good	hospital_good	sagital	139×147×128	0.75	91	2.64
49-badrecon	hospital_bad	sagital	125×147×128	0.75	45	2.47
66-badrecon	hospital_bad	sagital	146×147×132	0.75	64	2.42
05-badrecon	hospital_bad	sagital	133×120×122	0.75	80	2.78
96-badrecon	hospital_bad	sagital	139×132×136	0.75	54	2.7
t2-t21	JC	axial	180×221×180	0.50	81	2.2
t2-t22	JC	axial	180×221×180	0.50	75	2.17
t2-t23	JC	axial	180×221×180	0.50	86	2.2
t2-t24	JC	axial	180×221×180	0.50	87	2.3
t2-t25	JC	axial	180×221×180	0.50	89	2.31

Cuadro II
ENTORNO DE HARDWARE Y SOFTWARE

Componente	Especificación
Plataforma	Google Colaboratory
CPU	Intel Xeon @ 2.20 GHz, 2 núcleos
RAM	≈12.7 GB
GPU	NVIDIA T4 (solo entrenamiento CNN)
Sistema	Ubuntu 22.04 LTS
Python	3.10.x
Librerías	OpenCV 4.x, scikit-image 0.21.x, PyTorch
Formato	NIfTI (.nii), nibabel

III-A. Entorno experimental

Los experimentos se ejecutaron íntegramente en Google Colaboratory sobre la instancia de CPU estándar, sin GPU ni TPU para el *pipeline* clásico; la red neuronal se entrenó con la GPU gratuita disponible. La Tabla II resume el entorno. El *pipeline* clásico es determinista: ante la misma entrada produce siempre la misma máscara, lo que favorece la reproducibilidad.

IV. METODOLOGÍA

El *pipeline* propuesto se organiza en cinco etapas secuenciales más una etapa de validación con aprendizaje profundo. El orden es determinante: la normalización precede al realce, el realce precede al filtrado, y el filtrado precede a la segmentación.

IV-A. Etapa I — Análisis digital

Se caracterizó cada imagen determinando el tamaño de la matriz, la resolución espacial (mm/píxel) y la resolución de intensidad. Las intensidades se normalizaron mediante recorte por percentiles ($p_{\text{low}} = 0,5$, $p_{\text{high}} = 99,5$) y reescalado al intervalo $[0, 1]$:

$$I_n = \frac{\text{clip}(I, q_{0,5}, q_{99,5}) - q_{0,5}}{q_{99,5} - q_{0,5} + \varepsilon} \quad (1)$$

donde q_p denota el percentil p de la intensidad. Se analizó el histograma de cada volumen y se evaluaron transformaciones de realce. La Fig. 1 compara los histogramas original y ecualizado de los diez volúmenes; la Fig. 2 muestra la ecualización adaptativa resultante. La ecualización redistribuye la masa de intensidades concentrada en valores bajos hacia un rango más uniforme, mejorando el contraste del LCR.




Figura 1. Etapa I — Histogramas de intensidad (azul: original; naranja: ecualizado) de los diez volúmenes en escala logarítmica. La distribución original concentra la masa en intensidades bajas (fondo y tejido), mientras que la ecualización expande el rango útil para realzar el LCR hiperintenso.




Figura 2. Etapa I — Imágenes con ecualización adaptativa de contraste (CLAHE) de los diez volúmenes. CLAHE compensa la inhomogeneidad de campo y realza localmente el contraste entre el LCR y el tejido cerebral.

IV-A1. Transformaciones de intensidad: Además de la ecualización de histograma, se evaluaron las transformaciones gamma ($s = cr^\gamma$) y logarítmica ($s = c \log(1 + r)$). La transformación logarítmica expande los tonos oscuros y comprime los claros, útil cuando el LCR es muy brillante respecto al fondo; la transformación gamma con $\gamma < 1$ realza las regiones oscuras. En la práctica, la combinación de normalización por percentiles y CLAHE resultó más efectiva que las transformaciones globales para realzar el contraste local del LCR sin saturar el tejido circundante, por lo que se adoptó como base para la segmentación.

IV-B. Etapa II — Preprocesamiento y reducción de ruido

El ruido predominante en imágenes de magnitud de MRI sigue una distribución Riciana, de naturaleza no impulsiva.

Por ello se priorizó el filtrado lineal sobre el de mediana: un filtro gaussiano de soporte reducido,

$$I_s = I * G_\sigma, \quad G_\sigma(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/(2\sigma^2)}, \quad (2)$$

preserva los gradientes continuos necesarios para una umbralización estable del LCR, mientras que el filtro de mediana, óptimo para ruido impulsivo, redondea las esquinas del atrio. Se compararon ambos mediante el error cuadrático medio (MSE) respecto a la imagen original y mediante evaluación visual del borde ventricular (Fig. 3). La cadena final combina filtrado de mediana ligero, CLAHE y filtrado bilateral, que suaviza preservando bordes al ponderar por cercanía espacial y de intensidad. La intensidad del suavizado se adapta según la SNR estimada por corte.




Figura 3. Etapa II — Comparación de filtros sobre t_2-t_{24} : original, filtro gaussiano ($\sigma = 1,0$), filtro de mediana ($k = 3$) y mapa de diferencia absoluta. El MSE cuantifica la magnitud del suavizado.

IV-C. Etapa III — Segmentación ventricular

La segmentación constituye la contribución central del trabajo. En MRI T2 fetal, la estructura más hiperintensa no es el ventrículo lateral sino el LCR subaracnoideo que rodea la corteza; una semilla basada únicamente en intensidad tiende a ubicarse en dicha periferia. El método procede así:

1. Se obtiene la máscara cerebral por umbralización de Otsu y relleno de huecos, y se **erosiona** para conservar la región intracerebral interna, excluyendo el LCR subaracnoideo periférico.
2. Se detecta la cisura interhemisférica mediante tres anclas (centroide y muescas frontal y occipital) y se divide el cerebro en hemisferios, excluyendo una banda central fina que evita el cavum y el tercer ventrículo.
3. En cada hemisferio se coloca una semilla sobre el LCR más brillante de la región interna (percentil alto), priorizando el componente del atrio (mitad posterior-inferior), donde se mide el diámetro de Cardoza.
4. La semilla se expande mediante crecimiento de región acotado, con detección de fugas por salto de área, refinamiento morfológico (apertura y cierre) y eliminación de objetos pequeños, conservando un único componente por hemisferio.

El crecimiento de región se formaliza como sigue. Sea S_0 la semilla y B la región interna del hemisferio. En cada iteración t se umbraliza con un percentil decreciente p_t y se conserva el componente conexo C que intersecta la máscara actual:

$$M_{t+1} = \{ C : C \subseteq (I > q_{p_t}) \cap B, C \cap M_t \neq \emptyset \}, \quad (3)$$

deteniéndose si el incremento de área excede un factor de fuga ($|M_{t+1}| > \lambda |M_t|$) o el tope anatómico ($|M_{t+1}| > \tau |B|$). Esta detección de fuga por salto de área evita que la máscara se expanda hacia el tálamo o la corteza a través de puentes finos de intensidad.

La selección del corte axial óptimo busca el plano en el que aparecen dos componentes de LCR interno simétricos, uno por hemisferio, correspondiente al plano transventricular. La Fig. 4 ilustra los métodos de umbralización y refinamiento, y la Fig. 5 muestra el proceso completo sobre el caso de referencia t_2-t_{24} .

IV-D. Etapa IV — Cuantificación

A cada máscara ventricular se le ajusta el rectángulo de área mínima rotado. El lado menor de dicho rectángulo corresponde




Figura 4. Etapa III — Métodos de segmentación sobre t_2-t_{24} : preprocesado, umbral global (percentil 90), umbral de Otsu y máscara final tras refinamiento morfológico.

al ancho atrial perpendicular, equivalente al diámetro atrial clínico. El uso del rectángulo *rotado* en lugar del recto mide el ancho real cuando el ventrículo está inclinado. La conversión de píxeles a milímetros emplea la resolución espacial. El cálculo se realiza por separado para cada hemisferio y se reporta el valor mayor. Adicionalmente se calculan descriptores morfológicos: área, excentricidad, relación de ejes mayor/menor y compacidad, definida como

$$C = \frac{4\pi A}{P^2}, \quad (4)$$

donde A es el área y P el perímetro de la región.

IV-E. Etapa V — Clasificación diagnóstica

El diámetro atrial estimado se compara contra el criterio de Cardoza para asignar la categoría diagnóstica. La Fig. 6 muestra la escala diagnóstica con la ubicación de los diez volúmenes medidos.

IV-F. Validación — Red neuronal convolucional

Como segundo criterio se entrenó una Attention U-Net con codificador EfficientNet-B0 preentrenado en ImageNet mediante *transfer learning*. La arquitectura U-Net recupera el detalle fino de los bordes gracias a sus conexiones de salto; las compuertas de atención [4] suprimen las regiones irrelevantes, favoreciendo la segmentación de la estructura pequeña que constituye el ventrículo. EfficientNet-B0 [5] se seleccionó por su eficiencia paramétrica (aproximadamente 5 millones de parámetros), lo que reduce el sobreajuste en un conjunto pequeño. El *transfer learning* es necesario dado el reducido número de volúmenes [6]. La función de pérdida combina Dice y entropía cruzada binaria,

$$\mathcal{L} = 0,5 \mathcal{L}_{\text{Dice}} + 0,5 \mathcal{L}_{\text{BCE}}, \quad (5)$$

para equilibrar la estabilidad del gradiente con el foco en la clase minoritaria. El entrenamiento se realizó en dos fases: ajuste del decodificador con el codificador congelado, seguido de *fine-tuning* completo con tasa de aprendizaje reducida. La Fig. 7 presenta las curvas de entrenamiento.

IV-G. Parámetros del pipeline

La Tabla III resume los parámetros de cada etapa, calibrados sobre los volúmenes axiales de referencia. El orden de las operaciones es determinante: la normalización precede al realce para no amplificar el ruido de fondo; CLAHE precede a la umbralización para homogeneizar el contraste local; la




Figura 5. Caso de referencia $t2-t24$ (Normal, $D = 9,34$ mm en la medición manual de referencia; $z = 90$): corte original, preprocesado (CLAHE + bilateral), segmentación completa (izquierdo en azul, derecho en rojo; cisura en cian) y medición del diámetro atrial mediante el rectángulo de área mínima ($L=9.3$ mm, $R=8.8$ mm).




Figura 6. Etapa V — Escala diagnóstica del diámetro atrial según el criterio de Cardoza, con la posición de los diez volúmenes. Todos se clasifican como normales (< 10 mm).




Figura 7. Curvas de entrenamiento de la Attention U-Net: pérdida combinada Dice+BCE (entrenamiento y validación) y coeficiente Dice de validación, con el mejor desempeño alcanzado en la época 9 (Dice=0.7225).

erosión de la máscara cerebral precede a la siembra para excluir el LCR subaracnoideo; y la apertura precede al cierre para eliminar artefactos antes de rellenar discontinuidades.

IV-H. Métricas de evaluación

Dadas la predicción P y la referencia G , se emplean:

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \quad \text{IoU} = \frac{|P \cap G|}{|P \cup G|}, \quad (6)$$

relacionadas por $\text{IoU} = \text{Dice}/(2 - \text{Dice})$. El coeficiente de variación (CV) del diámetro entre cortes adyacentes cuantifica la consistencia de la medición.

Cuadro III
ETAPAS Y PARÁMETROS DEL *pipeline*

E	Operación	Parámetros
1	Normalización percentil	$p_{\text{low}} = 0,5$, $p_{\text{high}} = 99,5$
2	Filtro de mediana	$k = 3$
3	CLAHE	$\text{clip} = 0,005$, $\text{nbins} = 256$
4	Filtro gaussiano	$\sigma = 1,0$ (adapt. SNR)
5	Filtro bilateral	$d = 9$, $\sigma_c = \sigma_s = 50$
6	Máscara cerebral	Otsu + relleno; erosión 0,18
7	Banda central excluida	$0,045 W_{\text{cerebro}}$
8	Siembra (LCR interno)	percentil 91
9	Crecimiento acotado	piso p85, tope 0,05 A
10	Morfología	apertura $r=2$, cierre $r=3$
11	Eliminación objetos	$A_{\text{min}} = 50$ px

Cuadro IV
CUANTIFICACIÓN DEL DIÁMETRO ATRIAL Y CLASIFICACIÓN (ETAPA IV-V)

Volumen	D izq (mm)	D der (mm)	D máx (mm)	ÁreaL (mm ²)	ÁreaR (mm ²)	Clase
56-good	6.89	4.50	6.89	71	35	Normal
49-badrecon	6.00	4.99	6.00	56	46	Normal
66-badrecon	8.25	5.25	8.25	73	35	Normal
05-badrecon	6.00	7.50	7.50	65	53	Normal
96-badrecon	5.70	8.40	8.40	75	82	Normal
t2-t21	4.43	5.59	5.59	48	77	Normal
t2-t22	6.10	5.81	6.10	82	72	Normal
t2-t23	6.04	6.71	6.71	67	71	Normal
t2-t24	5.14	5.81	5.81	57	64	Normal
t2-t25	4.47	5.59	5.59	49	67	Normal

V. RESULTADOS

V-A. Cuantificación del diámetro atrial

La Tabla IV presenta los diámetros atriales estimados, las áreas ventriculares y la clasificación diagnóstica de los diez volúmenes. Todos los casos se clasificaron como normales, con diámetros entre 5.6 y 8.4 mm, consistente con cerebros fetales sin dilatación ventricular. Los volúmenes axiales (JC) produjeron mediciones más simétricas entre hemisferios.

Cuadro V
DESCRIPTORES MORFOLÓGICOS POR HEMISFERIO (ETAPA IV)

Volumen	Ecc.L	Ecc.R	Ratio L	Ratio R	Comp.L	Comp.R
56-good	0.803	0.845	1.68	1.87	0.932	0.944
49-badrecon	0.829	0.891	1.79	2.2	0.919	0.861
66-badrecon	0.55	0.475	1.2	1.14	1.031	1.161
05-badrecon	0.876	0.464	2.07	1.13	0.844	0.979
96-badrecon	0.949	0.943	3.18	2.99	0.598	0.334
t2-t21	0.955	0.935	3.36	2.81	0.528	0.641
t2-t22	0.953	0.95	3.29	3.2	0.498	0.505
t2-t23	0.906	0.878	2.37	2.09	0.661	0.669
t2-t24	0.931	0.906	2.74	2.37	0.624	0.659
t2-t25	0.939	0.925	2.92	2.63	0.654	0.644

Cuadro VI
DESEMPEÑO POR VOLUMEN DE LA CNN (VALIDACIÓN)

Volumen	Tipo	Dice	IoU	Exact.	CV(%)
56-good	hospital_good	0.697	0.535	0.988	34.7
49-badrecon	hospital_bad	0.831	0.711	0.974	16.8
66-badrecon	hospital_bad	0.796	0.661	0.956	36.4
05-badrecon	hospital_bad	0.79	0.653	0.985	20.0
96-badrecon	hospital_bad	0.823	0.699	0.978	32.1
t2-t21	JC	0.806	0.675	0.989	20.8
t2-t22	JC	0.855	0.747	0.958	4.8
t2-t23	JC	0.816	0.689	0.957	10.0
t2-t24	JC	0.823	0.699	0.971	11.5
t2-t25	JC	0.831	0.711	0.962	20.0

Cuadro VII
DESEMPEÑO DE LA CNN AGREGADO POR GRUPO

Grupo	n	Dice	IoU	Exactitud
JC (axial)	5	0.835	0.722	0.988
Hospital good	1	0.705	0.545	0.968
Hospital bad	4	0.817	0.694	0.951
Total	10	0.814	0.694	0.971

V-B. Descriptores morfológicos

La Tabla V reporta los descriptores morfológicos por hemisferio. La excentricidad elevada (0.90–0.95) en los volúmenes axiales refleja la forma alargada del atrio ventricular, mientras que los volúmenes hospitalarios sagitales presentan formas más variables por la orientación del corte y la mayor presencia de ruido.

V-C. Validación con la red neuronal

La Tabla VI resume el desempeño por volumen de la Attention U-Net, evaluado mediante Dice, IoU, exactitud y el CV del diámetro. La Tabla VII agrega estos valores por grupo. El grupo axial (JC) obtuvo el mejor desempeño (Dice 0.835), consistente con su mayor calidad de adquisición, mientras que los volúmenes hospitalarios de reconstrucción deficiente presentaron un desempeño ligeramente inferior por la presencia de artefactos. El desempeño global alcanzó un Dice promedio de 0.814 y un IoU de 0.694.




Figura 8. Desempeño de la CNN por grupo (Dice, IoU, exactitud). La línea discontinua indica el umbral de referencia de IoU (0.72). El grupo axial (JC) ofrece el mejor desempeño, consistente con su mayor calidad de adquisición.

V-D. Análisis por grupo

La Fig. 8 compara visualmente el desempeño de la red por grupo. Se observa una clara estratificación por calidad de adquisición: el grupo axial (JC) supera el umbral de referencia de IoU (0.72), mientras que el grupo hospitalario de buena calidad, pese a su única muestra, queda por debajo debido a la orientación sagital y al menor número de cortes útiles. El grupo hospitalario deficiente, tras el filtrado NLM, recupera un desempeño intermedio. Esta estratificación confirma que el factor dominante en la calidad de la segmentación es la calidad de adquisición y reconstrucción, más que el tipo de tejido o la presencia de patología.

V-E. Comparativa visual de los diez volúmenes

La Fig. 9 presenta la segmentación bilateral final de los diez volúmenes. Los volúmenes axiales (fila inferior) muestran segmentaciones simétricas y anatómicamente consistentes, con los atrios ventriculares claramente delimitados. Los volúmenes hospitalarios (fila superior), adquiridos en plano sagital y con menor SNR, presentan máscaras más irregulares, lo que evidencia la sensibilidad del método a la calidad de reconstrucción.

V-F. Caso adicional de validación

La Fig. 10 muestra el *pipeline* completo aplicado al volumen t2-t25, confirmando la reproducibilidad del método en un segundo volumen axial independiente. La segmentación bilateral mantiene la coherencia anatómica y la medición del diámetro atrial permanece dentro del rango normal.

VI. DISCUSIÓN

VI-A. Confusión LCR ventricular vs. subaracnoideo

El principal hallazgo metodológico es que la confusión entre el LCR ventricular y el subaracnoideo constituye la causa más frecuente de error en la segmentación basada en intensidad. La restricción de la búsqueda a la región intracerebral interna, junto con la selección del corte por presencia de dos componentes ventriculares simétricos, mejora sustancialmente la consistencia anatómica de las máscaras. Sin esta restricción, la semilla de mayor intensidad se ubica en el espacio subaracnoideo periférico y la segmentación falla.




Figura 9. Segmentación ventricular bilateral de los diez volúmenes (izquierdo en azul, derecho en rojo, cisura en cian). Fila superior: volúmenes hospitalarios (sagitales). Fila inferior: volúmenes axiales JC de alta calidad.




Figura 10. Pipeline de segmentación sobre t2-t25 (axial, $z = 89$): original, preprocesado, segmentación bilateral y medición del diámetro atrial.

VI-B. Efecto de la calidad de adquisición

Los volúmenes axiales de alta calidad produjeron segmentaciones más confiables ($CV < 0.21$) que los hospitalarios de mala reconstrucción, lo que refleja la sensibilidad del método a la SNR y a los artefactos. El filtrado NLM aplicado a los volúmenes deficientes mitiga parcialmente el ruido, pero no recupera la estructura perdida en la reconstrucción. Esta dependencia es coherente con la naturaleza basada en intensidad del método clásico.

VI-C. Aporte de la red neuronal

La red neuronal, entrenada sobre pseudo-etiquetas del *pipeline* clásico, aporta valor como visualizador de segundo criterio y reproduce las máscaras de referencia aprovechando características transferidas de ImageNet. No obstante, su desempeño está acotado por la calidad de dichas pseudo-etiquetas: la red aprende a replicar el pipeline clásico, no una verdad anotada por radiólogos.

VI-D. Relación de los descriptores con la severidad

Aunque todos los casos del conjunto resultaron normales, los descriptores morfológicos permiten anticipar cómo cambiarían con la severidad. La excentricidad y la relación de

ejes tienden a disminuir a medida que el ventrículo se dilata y adopta una forma más redondeada, mientras que el área y la compacidad aumentan. Por tanto, un seguimiento longitudinal de estos descriptores podría complementar la medición puntual del diámetro atrial, aportando información sobre la evolución de la dilatación.

VI-E. Comparación con el estado del arte

Los métodos de aprendizaje profundo para segmentación de tejido cerebral fetal alcanzan coeficientes Dice superiores a 0.85 cuando se dispone de anotaciones manuales a nivel de píxel, como en el *benchmark* FeTA [9]. El Dice global de 0.814 obtenido en este trabajo se sitúa por debajo de ese rango, pero con tres ventajas prácticas: el *pipeline* clásico es interpretable y determinista; no requiere anotaciones manuales, ya que la red se entrena sobre pseudo-etiquetas automáticas; y la cuantificación del diámetro atrial se realiza directamente sobre la máscara mediante un criterio geométrico explicable. La diferencia de desempeño se concentra en los volúmenes hospitalarios de baja calidad, donde la ausencia de *ground truth* y los artefactos de reconstrucción degradan tanto las pseudo-etiquetas como el aprendizaje de la red. Esto es coherente con la literatura, que señala la calidad y disponibilidad de datos anotados como la principal barrera en el análisis de imágenes fetales.

VII. LIMITACIONES

El estudio presenta varias limitaciones. Primero, no se dispone de un *ground truth* radiológico: la red se entrena y evalúa contra pseudo-etiquetas del *pipeline* clásico, por lo que el Dice reportado mide concordancia entre métodos y no respecto a una verdad anotada por especialistas. Segundo, la medición se concentra en el atrio y en un único plano; no se incorporan las

referencias frontal y occipital ni una estimación volumétrica tridimensional. Tercero, el tamaño de la muestra es reducido (diez volúmenes). Cuarto, en los volúmenes hospitalarios sagitales de baja calidad la segmentación es menos robusta, lo que se refleja en mayores valores de CV y en máscaras más irregulares. Finalmente, la robustez ante variaciones de orientación depende de parámetros que pueden requerir ajuste por adquisición.

VIII. TRABAJO FUTURO

Aunque los resultados obtenidos demuestran la viabilidad de la metodología propuesta para la segmentación y cuantificación automática de los ventrículos laterales fetales, existen diversas líneas de investigación que permitirían incrementar su precisión, robustez y utilidad clínica.

En primer lugar, resulta fundamental incorporar anotaciones manuales realizadas por radiólogos expertos y especialistas en medicina fetal. Actualmente, la red neuronal fue entrenada utilizando pseudo-etiquetas generadas por el pipeline clásico, por lo que su capacidad de aprendizaje está limitada por los errores inherentes a dichas segmentaciones automáticas. La construcción de una base de datos con máscaras validadas clínicamente permitiría entrenar modelos supervisados de mayor precisión y evaluar el desempeño mediante una referencia anatómica real.

Asimismo, se propone ampliar significativamente el tamaño y la diversidad de la base de datos. La inclusión de estudios provenientes de distintos hospitales, equipos de resonancia magnética, protocolos de adquisición y edades gestacionales permitiría desarrollar modelos con mayor capacidad de generalización. De igual forma, sería particularmente valioso incorporar casos de ventriculomegalia leve, moderada y severa, así como otras anomalías del sistema nervioso central, para evaluar el comportamiento del sistema en escenarios clínicos más complejos.

Otra línea de desarrollo consiste en evolucionar desde una evaluación bidimensional hacia un análisis completamente tridimensional. En lugar de realizar la cuantificación únicamente sobre el corte transventricular óptimo, podrían segmentarse los ventrículos en todo el volumen cerebral para calcular parámetros volumétricos precisos. Esta información complementaría la medición tradicional del diámetro atrial y permitiría estudiar patrones de crecimiento ventricular a lo largo de la gestación.

También se plantea incorporar algoritmos avanzados de corrección de orientación y normalización anatómica. Esto permitiría analizar automáticamente estudios adquiridos en diferentes planos y posiciones fetales sin necesidad de ajustes manuales, incrementando la robustez del sistema frente a variaciones propias de la práctica clínica real.

Desde la perspectiva del aprendizaje profundo, sería interesante evaluar arquitecturas más recientes, como nnU-Net, Swin-UNet, TransUNet o modelos híbridos basados en Transformers, los cuales han mostrado resultados sobresalientes en segmentación biomédica. Asimismo, podrían implementarse estrategias de aumento de datos más sofisticadas, incluyendo deformaciones elásticas, simulación de movimiento fetal y

variaciones de intensidad, con el fin de mejorar la capacidad de generalización de la red.

Adicionalmente, futuros trabajos podrían integrar información multimodal proveniente tanto de resonancia magnética como de ultrasonido obstétrico. La combinación de ambas modalidades permitiría aprovechar las ventajas de cada técnica y generar herramientas de apoyo diagnóstico más completas para la evaluación prenatal.

Finalmente, se contempla el desarrollo de una plataforma clínica interactiva que permita la carga automática de estudios DICOM o NIfTI, la visualización de las segmentaciones generadas, la medición automática de biomarcadores ventriculares y la generación de reportes preliminares para apoyo al especialista. Esta herramienta podría representar un paso importante hacia la transferencia tecnológica de la metodología propuesta y su eventual aplicación en entornos hospitalarios reales.

IX. CONCLUSIÓN

Este trabajo implementó y evaluó un *pipeline* semiautomatizado capaz de segmentar y cuantificar los ventrículos laterales en MRI fetal T2, produciendo segmentaciones anatómicamente consistentes y mediciones de diámetro atrial conformes al criterio de Cardoza. La estrategia de región intracerebral interna y la selección de corte por simetría ventricular resultaron determinantes para la calidad de la segmentación. Sobre los diez volúmenes evaluados, el sistema alcanzó un Dice promedio de 0.814 e IoU de 0.694, con los volúmenes axiales de alta calidad produciendo las segmentaciones más confiables ($CV < 0.21$). El *pipeline* es interpretable y la red neuronal aporta un segundo criterio de validación visual, sentando las bases para una herramienta de apoyo diagnóstico reproducible.

AGRADECIMIENTOS

Las autoras expresan su más sincero agradecimiento a la Dra. Mariana Sofía Flores, socia formadora de este proyecto, por su acompañamiento, guía y apoyo continuo durante el desarrollo de la investigación. Su experiencia, orientación y disposición para compartir conocimientos fueron fundamentales para comprender la relevancia clínica de la ventriculomegalia fetal, definir los objetivos del estudio y fortalecer la calidad científica y metodológica del trabajo. Sus observaciones y recomendaciones contribuyeron significativamente a la construcción de una propuesta con potencial aplicación en el ámbito del diagnóstico prenatal.

Asimismo, agradecemos al Dr. Rafael Pérez San Lázaro, al Dr. Juan Carlos Bello y al Dr. José Fernando González por sus valiosas aportaciones, asesoría especializada y retroalimentación durante las diferentes etapas del proyecto. Su experiencia en el análisis de imágenes médicas, neurodesarrollo fetal y evaluación clínica permitió enriquecer la interpretación de los resultados y fortalecer la discusión científica presentada en este trabajo.

De igual manera, reconocemos a los profesionales e instituciones que facilitaron el acceso a los estudios de resonancia magnética fetal utilizados en esta investigación. La disponibilidad de estos datos hizo posible el desarrollo, validación

y evaluación de las metodologías de procesamiento digital de imágenes y aprendizaje profundo propuestas.

Finalmente, agradecemos el uso de herramientas de inteligencia artificial como CLAUDE AI, como apoyo complementario para actividades de programación, análisis de información científica, depuración de código y documentación técnica, las cuales contribuyeron a optimizar el desarrollo del proyecto.

REFERENCIAS

- [1] J. D. Cardoza, R. B. Goldstein, and R. A. Filly, "Exclusion of fetal ventriculomegaly with a single measurement: the width of the lateral ventricular atrium," *Radiology*, vol. 169, no. 3, pp. 711–714, 1988.
- [2] G. Pilu *et al.*, "The clinical significance of fetal isolated cerebral borderline ventriculomegaly," *Ultrasound Obstet. Gynecol.*, vol. 14, no. 5, pp. 320–326, 1999.
- [3] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: convolutional networks for biomedical image segmentation," in *Proc. MICCAI*, LNCS 9351, pp. 234–241, 2015.
- [4] O. Oktay *et al.*, "Attention U-Net: learning where to look for the pancreas," in *Medical Imaging with Deep Learning (MIDL)*, 2018, arXiv:1804.03999.
- [5] M. Tan and Q. V. Le, "EfficientNet: rethinking model scaling for convolutional neural networks," in *ICML*, 2019, arXiv:1905.11946.
- [6] M. Raghu, C. Zhang, J. Kleinberg, and S. Bengio, "Transfusion: understanding transfer learning for medical imaging," in *NeurIPS*, 2019, arXiv:1902.07208.
- [7] F. Milletari, N. Navab, and S. A. Ahmadi, "V-Net: fully convolutional neural networks for volumetric medical image segmentation," in *3DV*, 2016, arXiv:1606.04797.
- [8] F. Isensee *et al.*, "nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation," *Nature Methods*, vol. 18, no. 2, pp. 203–211, 2021.
- [9] K. Payette *et al.*, "An automatic multi-tissue human fetal brain segmentation benchmark using the Fetal Tissue Annotation Dataset (FeTA)," *Scientific Data*, vol. 8, p. 330, 2021.
- [10] N. J. Tustison *et al.*, "N4ITK: improved N3 bias correction," *IEEE Trans. Med. Imaging*, vol. 29, no. 6, pp. 1310–1320, 2010.